

# *Time-Varying Factor Allocation*

Thomas Betton, Pierre Berthold, Chadi Rais, Pierre Liberge  
Université Paris-Dauphine

Janvier 2026

## Résumé

Ce rapport présente une réPLICATION empirique complète de l'article *Time-Varying Factor Allocation* de Vincenz et Zeissler (2022). L'objectif du papier est d'évaluer si l'utilisation de prédicteurs macroéconomiques et de marché, combinée à un cadre bayésien conservateur et à une allocation de type Black–Litterman sous contraintes, permet d'améliorer la performance d'un portefeuille multi-facteurs en hors-échantillon.

En nous appuyant sur l'article original et sur une présentation détaillant l'implémentation, nous reconstruisons l'ensemble de la chaîne empirique : données, construction des facteurs, régressions prédictives bayésiennes, allocation, et évaluation des performances. Les résultats sont analysés à l'aide de performances cumulées, d'information ratios, d'analyses par sous-périodes, de drawdowns et de tests de significativité par bootstrap. Le rapport discute enfin les différences avec le papier, les choix de calibration et les limites de l'approche.

## 1 Introduction et motivation

L'investissement factoriel est devenu un cadre dominant de la gestion d'actifs quantitative. De nombreux travaux documentent l'existence de primes de risque associées à des caractéristiques économiques telles que la valeur, le momentum ou le carry. Toutefois, la performance de ces facteurs est notoirement instable dans le temps, ce qui pose la question de l'opportunité d'une allocation dynamique.

L'article de Vincenz et Zeissler (2022) s'inscrit dans cette problématique et pose une question centrale : *l'information macroéconomique et de marché permet-elle d'améliorer l'allocation entre facteurs sans tomber dans le sur-apprentissage ?* Pour y répondre, les auteurs proposent une architecture combinant des prévisions bayésiennes volontairement conservatrices et une allocation Black–Litterman qui limite les écarts par rapport à un benchmark diversifié.

Ce projet vise à répliquer fidèlement cette approche et à évaluer empiriquement ses performances et sa robustesse.

## 2 Données et univers d'investissement

### 2.1 Classes d'actifs

L'univers d'investissement est multi-actifs et couvre quatre classes principales : devises (FX), matières premières, taux souverains et actions. Pour chaque classe, plusieurs facteurs long–short

sont construits à partir de signaux standards. Les données sont mensuelles et couvrent une période longue, de 1973 à 2018, sous réserve de disponibilité.

## 2.2 Traitement des données

Les données brutes font l'objet d'un nettoyage rigoureux. Les rendements extrêmes sont tronqués selon des bornes spécifiques à chaque classe d'actifs. Les séries sont alignées en fin de mois et seules les séries disposant d'un nombre suffisant d'observations sont conservées. Ce pré-traitement est crucial pour garantir la stabilité des estimations ultérieures.

# 3 Construction des facteurs

## 3.1 Méthodologie long–short

Les facteurs sont construits par tri en sextiles. À chaque date, les actifs sont classés selon un signal donné. Le portefeuille prend une position longue sur le sextile supérieur et une position courte sur le sextile inférieur, avec des pondérations égales. Les rendements sont calculés avec un décalage d'un mois afin d'éviter toute anticipation.

## 3.2 Facteurs par classe d'actifs

Pour les devises, quatre facteurs sont considérés : marché, carry, momentum et value. Les matières premières incluent cinq facteurs, notamment carry (roll yield), momentum, value et basis momentum. Les facteurs de taux reposent sur une approximation des rendements obligataires à partir des variations de yield, tandis que les facteurs actions sont construits à partir d'indices MSCI.

En raison de contraintes de données, l'implémentation répliquée comprend 17 facteurs contre 21 dans le papier original. La Figure 1 présente les rendements annuels des facteurs et illustre la forte hétérogénéité des performances dans le temps.

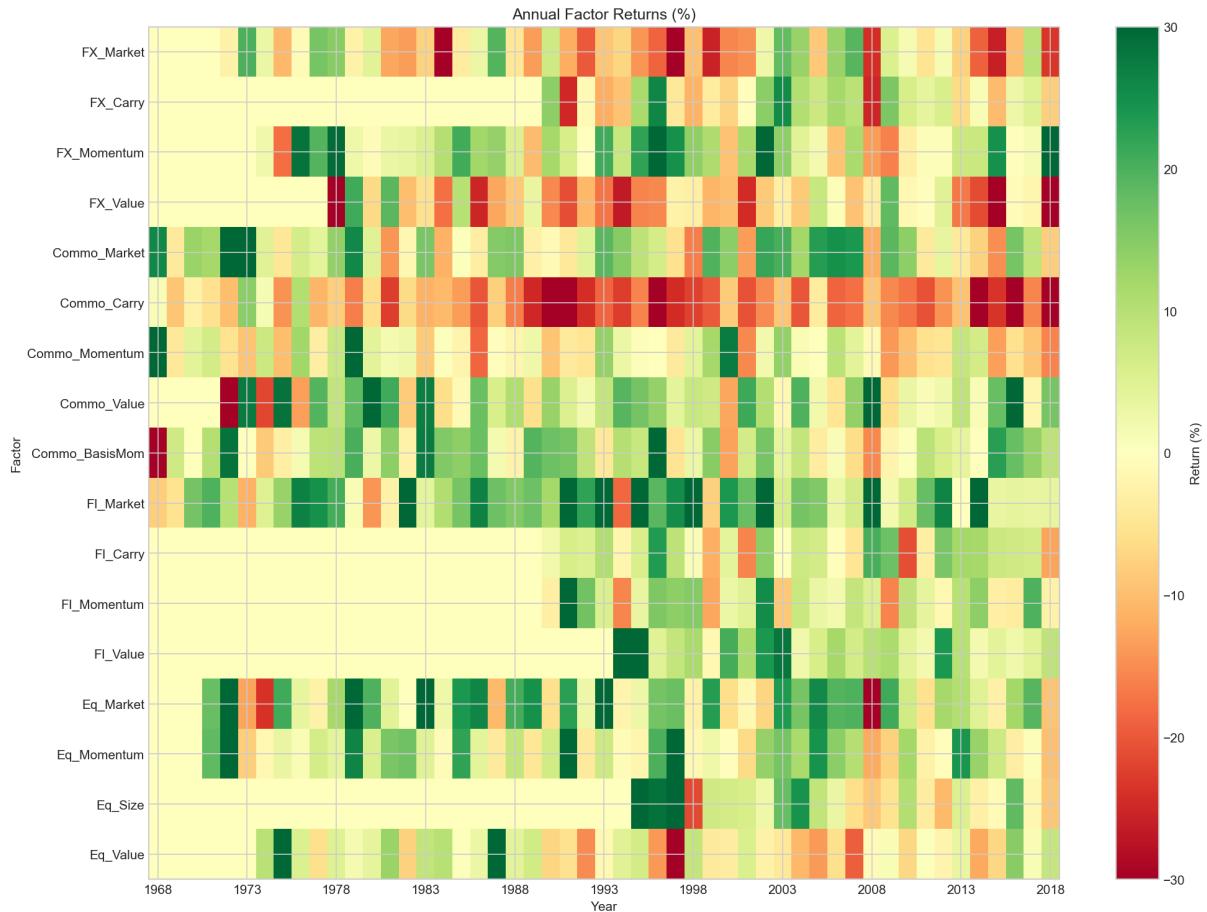


FIGURE 1 – Rendements annuels des facteurs

## 4 Normalisation par la volatilité

Afin de rendre les facteurs comparables en termes de risque, tous les rendements sont normalisés à une volatilité annualisée cible de 10%. Cette normalisation repose sur une estimation rolling de la volatilité sur 36 mois et inclut un plafonnement du levier. Cette étape est essentielle pour éviter que les résultats ne soient dominés par quelques facteurs très volatils.

## 5 Variables prédictives

L'article exploite 15 prédicteurs macroéconomiques et de marché, incluant des indicateurs d'activité économique, d'inflation, de politique monétaire et de stress financier. Les prédicteurs sont standardisés à l'aide d'une fenêtre expanding afin d'éviter tout biais de regard vers le futur. Dans la réPLICATION, 12 prédicteurs sont effectivement implémentés.

## 6 Régression bayésienne prédictive

Pour chaque paire facteur-prédicteur, une régression linéaire prédictive est estimée. Les auteurs soulignent que les estimations OLS classiques surestiment la prédictabilité. Pour limiter ce biais, un prior bayésien conservateur est imposé sur les coefficients, calibré de manière à induire

un  $R^2$  a priori inférieur à 1%. Le posterior correspond alors à une version fortement shrinkée de l'estimateur OLS.

Les prévisions sont produites dans un cadre expanding window et servent d'entrées au module d'allocation.

$$r_{f,t+1} = \alpha_f + \beta_f x_t + \varepsilon_{t+1}, \quad \varepsilon_{t+1} \sim \mathcal{N}(0, \sigma^2) \quad (1)$$

$$\beta_f \sim \mathcal{N}(0, \sigma_\beta^2), \quad \sigma_\beta^2 = R_{\text{prior}}^2 \cdot \frac{\text{Var}(r_f)}{\text{Var}(x)} \quad (2)$$

## 7 Allocation Black–Litterman

Le benchmark est un portefeuille équi-pondéré sur l'ensemble des facteurs disponibles. Les prévisions bayésiennes sont interprétées comme des *views* sur les rendements attendus. L'allocation est obtenue en maximisant une fonction d'utilité moyenne–variance sur les rendements actifs, pénalisée par le tracking error par rapport au benchmark.

L'optimisation est soumise à plusieurs contraintes pratiques : investissement total, long-only et borne maximale sur le poids de chaque facteur. Le tracking error moyen obtenu est de l'ordre de 2 à 3% annualisé, conformément au papier.

## 8 Résultats empiriques

### 8.1 Performances cumulées

La Figure 2 compare les performances cumulées des principales stratégies à celles du benchmark équi-pondéré. Les stratégies basées sur l'inflation, les taux courts et le momentum temporel surperforment nettement le benchmark sur l'ensemble de la période.

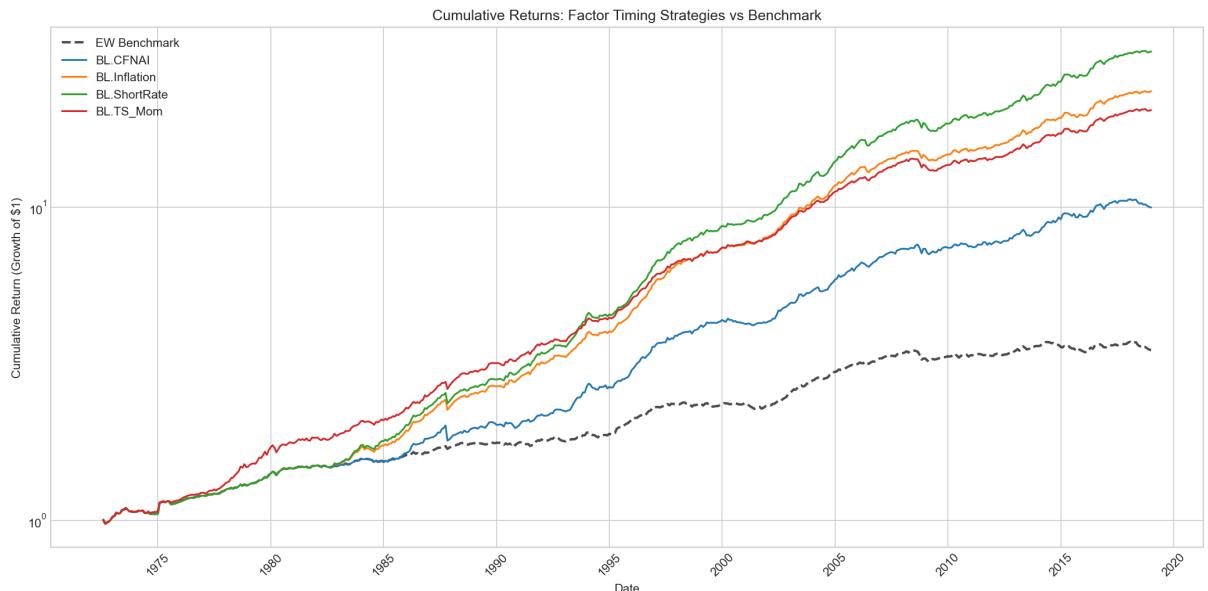


FIGURE 2 – Performances cumulées : stratégies vs benchmark

## 8.2 Information ratios et stabilité temporelle

Les information ratios moyens sont présentés dans la Figure 3. Plusieurs prédicteurs affichent des IR supérieurs à 0.5, seuil souvent considéré comme économiquement significatif.

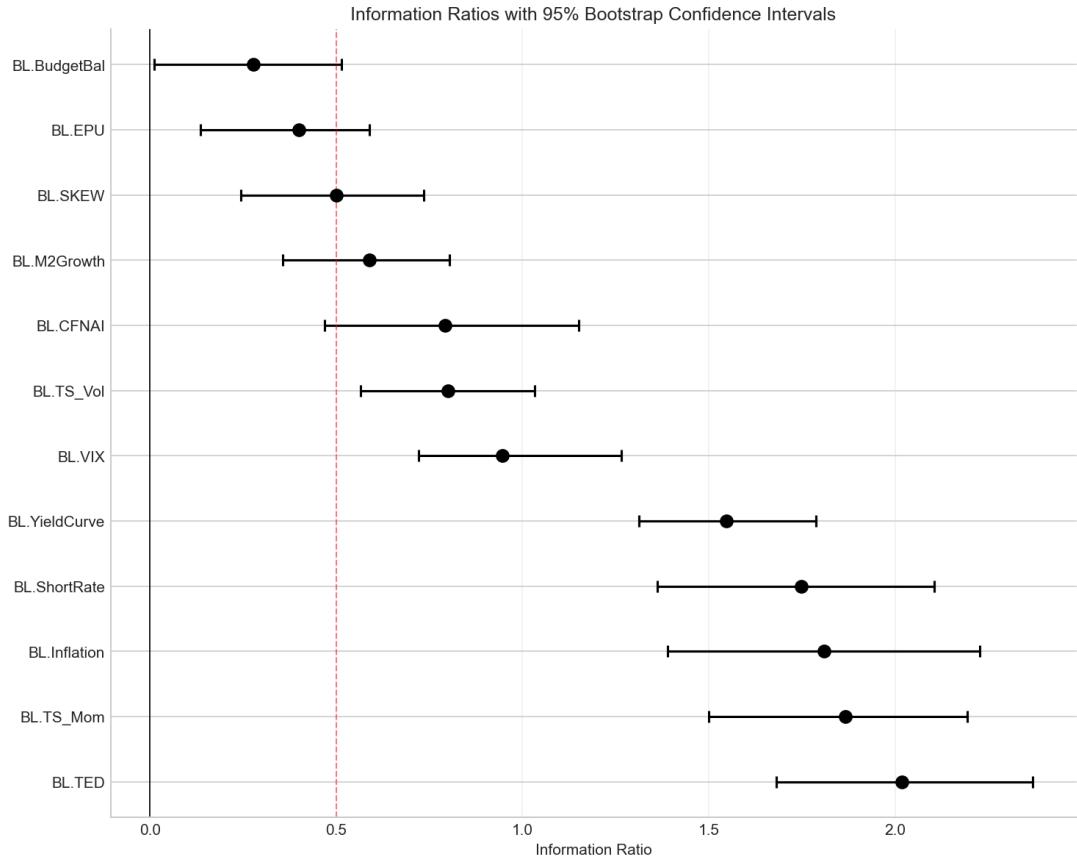


FIGURE 3 – Information ratios par stratégie

La Figure 4 montre les information ratios rolling sur 36 mois pour les meilleures stratégies. Bien que la performance varie dans le temps, les IR restent majoritairement positifs, ce qui suggère une certaine robustesse.

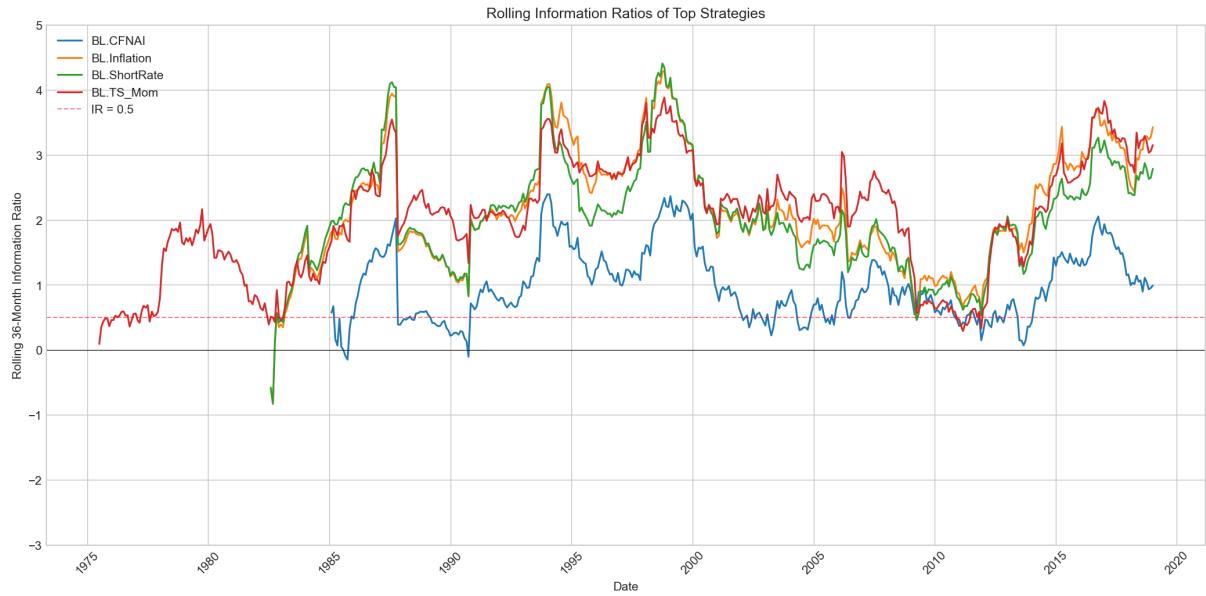


FIGURE 4 – Information ratios rolling (36 mois)

### 8.3 Analyse par sous-périodes

L’analyse par sous-périodes (Figure 5) montre que les prédicteurs macroéconomiques conservent un pouvoir prédictif sur différentes phases de marché, bien que leur performance relative varie.

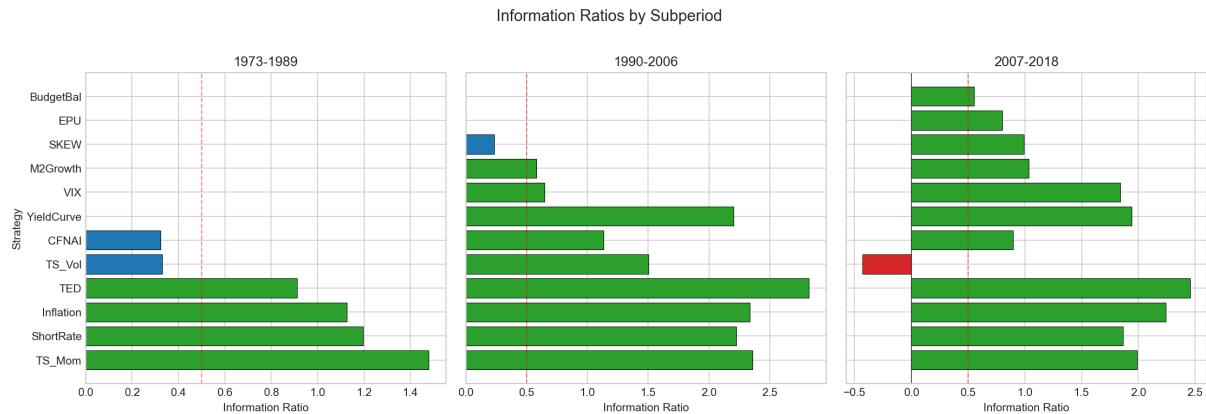


FIGURE 5 – Information ratios par sous-période

### 8.4 Drawdowns

La Figure 6 compare les drawdowns du benchmark et de la meilleure stratégie. Les stratégies actives n’éliminent pas les pertes, mais tendent à réduire l’ampleur et la durée des drawdowns par rapport au benchmark.

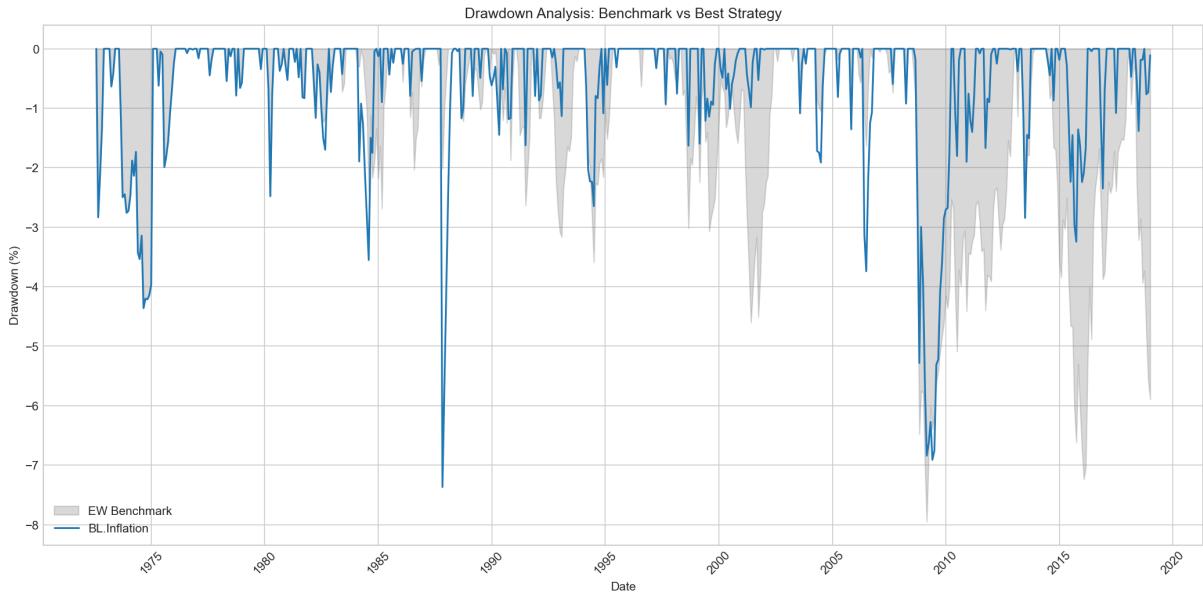


FIGURE 6 – Analyse des drawdowns

## 9 Tests de significativité

Les information ratios sont évalués à l'aide de bootstrap afin de construire des intervalles de confiance à 95%. Les résultats montrent que plusieurs stratégies restent significatives après correction pour tests multiples, en ligne avec les conclusions du papier.

## 10 Limites

La réPLICATION CONFIRME L'INTÉRÊT DU CADRE PROPOSÉ PAR VINCENZ ET ZEISSLER (2022). Toutefois, les résultats dépendent de plusieurs choix de calibration, notamment le degré de shrinkage bayésien et la mesure du risque. Par ailleurs, certaines différences avec le papier original (facteurs et prédicteurs manquants, proxys) peuvent affecter la diversification globale.

## 11 Extension empirique : prévision endogène des facteurs via VAR(1) roulant

### 11.1 Motivation

Le cadre répliqué suit l'approche proposée par Vincenz et Zeissler (2022), qui consiste à utiliser des prédicteurs macroéconomiques et de marché afin de produire des prévisions de rendements de facteurs via des régressions prédictives bayésiennes univariées avec un a priori très conservateur. Cette approche exploite une information exogène (macro → facteur), interprétée comme des *views* injectées dans un cadre d'allocation de type Black–Litterman.

Une limite naturelle de cette méthodologie est sa dépendance à des séries macroéconomiques potentiellement bruitées, révisées a posteriori ou publiées avec retard. En complément, nous proposons une extension purement *market-based* consistant à exploiter l'information contenue

dans la dynamique conjointe des facteurs eux-mêmes. L'intuition est que les facteurs peuvent présenter :

- une autocorrélation temporelle (momentum ou mean-reversion au niveau du facteur),
- des effets de propagation entre facteurs (*spillovers*),
- une dynamique instationnaire nécessitant une estimation adaptative.

## 11.2 Méthodologie : VAR(1) roulant sur rendements de facteurs

Soit  $f_t \in \mathbb{R}^N$  le vecteur des rendements de facteurs à la date  $t$ . Nous estimons un modèle vectoriel autorégressif d'ordre 1 :

$$f_t = c + Af_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \Sigma),$$

où  $c$  est un vecteur de constantes et  $A$  une matrice de coefficients  $N \times N$  capturant les dépendances croisées entre facteurs.

L'estimation est réalisée dans une fenêtre glissante de longueur  $L = 120$  mois, avec un minimum de 60 observations afin de garantir la stabilité statistique. À chaque date  $t$ , les coefficients sont estimés uniquement à partir de l'information disponible jusqu'à  $t - 1$ , assurant ainsi un cadre strictement hors échantillon et évitant tout biais de regard vers le futur.

Afin de limiter les problèmes de colinéarité et de sur-ajustement inhérents à l'estimation d'un VAR de dimension élevée, une régularisation ridge est appliquée aux coefficients (hors constante). Le paramètre de pénalisation est fixé à  $\alpha = 10^{-3}$ , ce qui permet de stabiliser les estimations tout en conservant une dynamique suffisamment flexible.

La prévision des rendements de facteurs à l'horizon  $t + 1$  est alors donnée par :

$$\hat{f}_{t+1}^{VAR} = \hat{c}_t + \hat{A}_t f_t.$$

## 11.3 Intégration dans le cadre d'allocation

Les prévisions issues du VAR(1) roulant sont interprétées comme un vecteur de rendements espérés  $\hat{\mu}_t^{VAR}$  et injectées dans le même moteur d'allocation que celui utilisé pour la réplication, à savoir un optimiseur de type Black–Litterman contraint. Les contraintes imposées sont identiques pour toutes les stratégies : portefeuille long-only, somme des poids égale à un, et borne maximale par facteur.

Cette homogénéité de traitement garantit que les différences de performance observées proviennent uniquement de la qualité des signaux prédictifs, et non d'un changement du mécanisme d'allocation.

## 11.4 Stratégie d'ensemble Bayes–VAR

En complément, nous construisons une stratégie d'ensemble combinant l'information exogène (macroéconomique) et endogène (dynamique des facteurs). Plus précisément, nous calculons :

1. une prévision moyenne bayésienne  $\hat{\mu}_t^{BayesAvg}$  obtenue en moyennant les prévisions issues de l'ensemble des prédicteurs macroéconomiques et de séries temporelles,

2. une prévision endogène  $\hat{\mu}_t^{VAR}$  issue du VAR(1) roulant.

Le signal d'ensemble est défini comme :

$$\hat{\mu}_t^{ENS} = \frac{1}{2}\hat{\mu}_t^{BayesAvg} + \frac{1}{2}\hat{\mu}_t^{VAR}.$$

Cette combinaison vise à capter simultanément les effets de cycle économique, de stress financier et de politique monétaire, ainsi que la dynamique propre aux facteurs financiers.

## 11.5 Résultats empiriques

Sur l'échantillon mensuel allant de juillet 1967 à décembre 2018 (618 observations), la stratégie basée uniquement sur le VAR(1) roulant affiche un rendement annualisé de 6.20% pour une volatilité de 5.16%, soit un ratio de Sharpe de 1.20 et un ratio d'information de 0.89 par rapport au benchmark équivalant.

La stratégie d'ensemble Bayes–VAR améliore légèrement ces résultats avec un rendement annualisé de 6.31%, une volatilité de 4.87% et un ratio de Sharpe de 1.29. Le drawdown maximal est également plus faible que pour la stratégie VAR seule, suggérant un meilleur compromis rendement–risque.

Les tests de significativité tenant compte de la multiplicité des stratégies évaluées (correction de Holm) confirment que les stratégies BL.VAR et BL.ENS\_BayesVAR restent statistiquement significatives au seuil de 5%.

## 11.6 Discussion et limites

Cette extension met en évidence l'intérêt d'exploiter la dynamique interne des facteurs en complément des prédicteurs macroéconomiques traditionnels. Le VAR capte des mécanismes de propagation et d'inertie qui ne sont pas nécessairement expliqués par la macroéconomie.

Toutefois, cette approche reste sujette à plusieurs limites : le nombre élevé de paramètres à estimer, la sensibilité aux choix de fenêtre et de régularisation, ainsi que l'absence de contraintes structurelles dans la matrice  $A$ . Des extensions naturelles incluraient l'utilisation de VAR parcimonieux (LASSO), de modèles à facteurs latents ou de structures bloc-diagonales par classe d'actifs.

## 12 Conclusion

Ce projet propose une réPLICATION empirique détaillée de *Time-Varying Factor Allocation*. Les résultats suggèrent que l'information macroéconomique peut être exploitée pour améliorer l'allocation multi-facteurs, à condition d'être intégrée dans un cadre conservateur limitant le sur-apprentissage. L'approche Black–Litterman apparaît particulièrement adaptée pour transformer des signaux prédictifs incertains en allocations stables et économiquement plausibles.

## Références

Vincenz, S., Zeissler, T. (2022). *Time-Varying Factor Allocation*. The Journal of Portfolio Management.